

ESS 배터리 수명 예측

DAY 1 / EDA 기반 모델 설계 전략

SKALA 울산 3반 · U095 이연주 · 2026.10.01

139

원본 배터리 셀

129

유효 수명 정답

115

품질 점검 후 주분석 셀

초기 100사이클의 방전 곡선 변화로 수명을 예측하는 회귀 전략을 설계했다. 제공된 세 Batch를 직접 분석하고, 데이터 품질·배치 차이·피쳐 중복을 검증 설계에 반영했다.

분석 범위	확인 결과	전략으로 연결
139개 원본 셀 / 3개 Batch	유효 수명 129개, 주분석 115개	정답 결측·종료 미확인·품질 경고를 기록
핵심 신호: $\log_{10} \text{Var}(\Delta Q)$	Batch별 Pearson r: -0.827 / -0.902 / -0.742	한 개 대표 피쳐부터 규제 회귀 시작
수명 분포 이동	Batch 2 단수명 71.8%, Batch 3 장수명 52.3%	Batch별 오차와 외삽 한계 보고
분류 타겟 500 기준	Batch 1: 0 대 46, 주분석 0 대 36	수치 수명 회귀 선택

01. 데이터 범위와 구조 확인

구분	파일 날짜	원본 셀	유효 정답	총 사이클 행	정책 수
Batch 1	2017-05-12	46	46	38,811	23
Batch 2	2018-02-20	47	39	26,904	20
Batch 3	2018-04-12	46	44	51,007	8

구조: Batch → 배터리 셀 → summary(사이클별 요약) / cycles(사이클 내부 시계열). 셀당 수명·정책·전압축이 있으며, 분석용 ID는 b1c0처럼 Batch와 파일 내 인덱스로 구성했다.

확인 항목	검사 결과	처리 원칙
초기 정보	139개 모두 사이클 5·100 및 Qdlin 10·100 배열 존재	summary.cycle로 실제 사이클 번호를 찾음
Qdlin / Vdlin	각각 1,000점, 전압 2.0~3.5 V	동일 전압축에서 Q100-Q10, 유한값 검사
결측	summary 수치의 NaN 0개, 수명 NaN 10개	0값은 결측 검사만으로 찾을 수 없어 별도 집계
표본 단위	원본 summary 총 116,722행 / 실제 셀 139개	모델은 배터리 셀당 1행

논문 공개 코드의 두 번째 파일은 2017-06-30이다. 이번 제공 파일은 2018-02-20(47셀)로 다르므로 논문의 124셀 실험을 그대로 재현한 것으로 표현하지 않는다. (1, 2)

02. 분석 대상 및 품질 기준


Batch	원본 → 주분석	보류 / 제외 사유
Batch 1	46 → 36	b1c0~4: 공개 코드상 계속 측정된 셀이나 후속 파일 부재. b1c8,10,12,13,22: 종료 미확인. 현재 종료 QD도 모두 0.91 Ah 초과.
Batch 2	47 → 39	b2c22,23,35~40: cycle_life가 NaN. 특수 프로토콜 8개로, 정답을 임의 대치하지 않음.
Batch 3	46 → 40	b3c2,23,32,37,42,43: 저자 공개 코드의 품질 경고 채널. 23,32는 정답도 NaN.

원본 전체 분포·곡선은 보존하고, 수명 상관분석은 전체 유효 정답과 주분석 집합을 모두 계산했다. 짧은 수명 자체는 삭제 사유가 아니다.

탐색 규칙	이유 / 영향
QD: $0 < QD \leq 1.5 \text{ Ah}$	시각화·초기 기울기에서만 적용. Batch 1/2/3에서 48/11/0행이 범위 밖. 0.88 Ah 이하라는 이유로 지우지 않음.
초기 요약: 사이클 2~100	첫 사이클 초기화 차이로 1번을 공통 제외. 온도·IR의 0 이하는 무효 후보, 충전시간 60분 초과는 중앙값에서 제외.
정제는 확정 진실이 아닌 분석 규칙	주분석/전체 유효 정답의 민감도 결과를 함께 저장. 미래 종료 정보는 타깃 품질 검사용이며 입력 피처에 사용하지 않음.

출처 (2)의 셀 경고 목록과 현재 원시 데이터 점검을 결합했다. Batch 1 수명 보정이나 Batch 간 셀 병합은 수행하지 않았다.

Q1-1. Batch별 수명 분포



구분	평균 / 중앙값	범위	단수명 <500	장수명 >1000
Batch 1	844.7 / 858.5	534~1,227	0/46 (0.0%)	10/46 (21.7%)
Batch 2	565.7 / 472.0	392~1,186	28/39 (71.8%)	3/39 (7.7%)
Batch 3	1,059.7 / 1,005.5	541~1,935	0/44 (0.0%)	23/44 (52.3%)

관찰: Batch 2는 짧은 수명에, Batch 3은 긴 수명에 상대적으로 집중된다. 비율의 분모는 정답이 있는 셀이다. 과제 측은 150~2,300으로 유지했고 실제 정답 범위는 392~1,935이다.

해석·시사점: 모든 Batch를 섞은 평균 성능만으로 일반화를 판단하지 않는다. Batch별·수명 구간별 오차를 보고하고, 학습 범위 밖 수명을 별도 분석한다.

Q1-2. 최단 수명 셀 분석

셀	수명	충전 정책	초기 QD 기울기	log10 Var(ΔQ)	Tavg 중앙값
b1c20	534	5.4C(80%)-5.4C	-0.000140	-3.367	32.11
b2c19	392	6C(60%)-3C	0.000022	-3.292	32.79
b3c28	541	3.7C(31%)-5.9C-newstructure	-0.000198	-3.451	35.71

관찰: b2c19는 초기 QD 기울기가 양수인데도 수명이 392로 짧다. b1c20과 b3c28은 초기 기울기가 음수이다. 같은 방향의 초기 용량 변화가 모든 Batch에서 같은 의미를 갖지는 않는다.

해석: 충전 정책, 온도, 저항, ΔQ 를 함께 봐야 한다. 이 자료만으로 셀별 고장 기전이나 “왜 유독 짧은가”의 단일 원인을 확정할 수 없다. 상관 분석은 원인 후보를 좁히는 단계이다.

시사점: b1c20, b2c19, b3c28을 유지하고 DAY 2의 큰 오차 셀 분석 대상으로 추적한다. Batch 1·3의 최단 셀도 500 이상이므로 과제의 단수명 집단 (<500)과 구분한다.

통계적 이상치: Batch별 1.5×IQR 기준에서 하위 이상치는 모두 0개, 상위은 0/9/3개이다. Batch 2 상위 9개는 모두 newstructure 조건이다. 짧은 수명과 통계적 이상치를 구분하며, 다른 실험 조건일 수 있어 자동 삭제하지 않는다. 셀별 목록은 lifetime_outliers.csv에 있다.

선택지	데이터 근거	결정
500 기준 이진 분류	Batch 1 전체 0:46 / 주분석 0:36. 단수명 셀이 없어 안정적 분류 검증이 어려움.	이번 과제에서 선택하지 않음
초기 100사이클 회귀	셀 간 수치 수명 차이와 ΔQ 신호를 활용. 운영에서 상대적 교체 우선순위 검토 가능.	cycle_life 회귀 선택

Q1-3. 최단 수명 셀 비교


셀 / 수명	log Δ Q 분산: 셀 / Batch 중앙값	Batch 내 백분위	동일 정책 다른 셀: n / 수명 중앙값
b1c20 / 534	-3.367 / -3.786	97.2%	1 / 559.0
b2c19 / 392	-3.292 / -3.487	82.1%	1 / 408.0
b3c28 / 541	-3.451 / -4.150	100.0%	2 / 719.5

관찰: 최단 셀의 Δ Q 로그분산은 Batch 내 97.2 / 82.1 / 100백분위이다. b1c20·b2c19와 같은 정책의 다른 셀도 각각 559·408사이클로 짧아 충전 조건과의 관련 가능성이 있다. b3c28의 Tavg는 35.71° C로 Batch 중앙값 34.13° C보다 높다. 다만 대조 실험이 아니므로 단일 원인으로 확정하지 않는다.

가설	이 자료에서 확인할 수 있는 근거	판단
초기 총용량 감소가 빠르기 때문인가?	b2c19는 기울기가 양수인데도 최단 수명이다.	모든 Batch에 통하는 단일 설명은 아니다.
초기 전압별 용량 변화가 큰가?	위 상대 비교와 Q3의 Δ Q-수명 음의 관계를 함께 확인한다.	유력한 위험 신호이며 피처로 반영한다.
온도·저항·충전 조건 때문인가?	셀별 값과 Batch 중앙값은 shortest_cell_comparison.csv에 기록한다.	관측 자료라 조건 교란을 제거하지 못한다.

시사점: 최단 셀은 오류로 자동 삭제하지 않는다. 개별 고장 원인은 확정하지 않되, 상대적으로 큰 Δ Q 변화라는 관측 근거를 주피처 선택에 연결한다. DAY 2에서는 이 셀들의 예측 잔차를 추적한다.

Q2-1. 방전 용량 열화 곡선




관찰: 다수의 셀에서 초기 용량이 약 1.1 Ah 부근에 모여 있다가 후반에 감소가 빨라진다. Batch 1에는 측정 종료 시 용량이 높게 남은 곡선이 있다. 정답 NaN은 회색, 나머지는 기록 수명에 따라 색을 매겼다.

해석: 전체 수명 종료가 모든 셀에서 같은 방식으로 관찰된 것은 아니다. 참고선 0.88 Ah는 공칭 1.1 Ah의 80%이다. 원래 cycle_life 필드와 임계값 교차 시점이 완전히 같다고 가정하지 않는다.

시사점: 기록 종료 길이를 수명 피쳐로 사용하지 않는다. 마지막 QD-전체 꺾적·knee는 EDA 해석용이며 초기 예측 모델 입력에서 제외한다.

Q2-2. 초기 100사이클 변화




관찰: 주분석 집합에서 초기 곡선들은 좁은 용량 구간에 모이고 일부는 증가한다. 같은 초기 용량을 가진 셀의 전체 수명은 크게 다를 수 있다.

Batch	원래 기울기-수명 r	평활 기울기-수명 r	순간 편차 셀 수
Batch 1	0.508	0.511	0
Batch 2	-0.445	-0.389	8
Batch 3	0.331	0.331	0

Batch 2의 급락 후 복귀를 지속 열화로 단정하지 않는다. 초기 2~100사이클 안에서 11점 이동 중앙값을 적용해 민감도를 점검했다. 순간 편차는 원래 값과 이동 중앙값의 차이가 0.02 Ah를 넘는 경우이며, 고장 판정 기준이 아니다.

시사점: QD 기울기는 보조 후보로 남기되 단독 결정 신호로 삼지 않는다. ΔQ 의 전압별 형태처럼 총용량이 놓치는 정보를 추가한다. 기울기는 원래 사이클 2~100의 유효 QD에 선형 적합한 값이다.

Q2-3. Knee point 후보




Batch	대표 셀 (최단 / 중앙순위 / 최장)	수명	knee 후보
Batch 1	b1c20 / b1c11 / b1c5	534 / 788 / 1,074	413 / 594 / 878
Batch 2	b2c19 / b2c16 / b2c34	392 / 472 / 1,186	304 / 365 / 965
Batch 3	b3c28 / b3c25 / b3c38	541 / 989 / 1,935	378 / 824 / 1,521

방법: 11점 이동 중앙값에 연속 두 직선을 적합했다. 단일 직선보다 SSE가 25% 이상 줄고 후기 기울기가 더 가파른 음수일 때 점선으로 표시했다. 상세 기울기·SSE 감소율은 notebooks/02_day1_edu.ipynb에 있다.

해석·한계: 후기 가속을 보여주는 탐색적 변화점이며 물리적 knee 정답은 아니다. 평활화·구간에 민감하고 전체 수명 정보를 사용하므로 예측 피처에서 제외한다.

Q3- 1. $\Delta Q(V)$ 와 수명 관계




Batch	주분석 n	Pearson r	Spearman ρ	정책 군집 bootstrap 95% 구간
Batch 1	36	-0.827	-0.826	$[-0.921, -0.659]$
Batch 2	39	-0.902	-0.709	$[-0.929, -0.442]$
Batch 3	40	-0.742	-0.759	$[-0.858, -0.567]$

계산: $\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$. 같은 1,000개 전압점에서 차이를 구하고 $\log_{10}(\text{표본분산})$ 을 계산했다. 전압축을 정렬해 면적의 부호도 일관되게 처리했다.

관찰·시사점: 로그분산은 세 Batch 모두 음의 관계를 보이며 핵심 피처 후보이다. 구간은 정책 단위 부트스트랩 1,000회(난수 42)로 계산했으며, 적은 정책 수 때문에 탐색적으로 해석한다.

Q3-2. $\Delta Q(V)$ 통계 피쳐




피쳐	계산 / 해석	모델 입력 결정
log_dq_var	ΔQ 표본분산(ddof=1)의 log10	주피쳐
min / mean / max / std	전압축에서 ΔQ 의 위치와 퍼짐	중복과 추가 가치를 내부 CV로 확인
skew / kurtosis	왜도와 초과첨도, bias=False	로그분산보다 약한 상관으로 후순위
signed area	전압 오름차순에서 ΔQ 적분 (Ah·V)	평균과 거의 중복, 우선 제외

관찰: Batch 2에서 단수명(<500)과 장수명(>1000)을 비교할 수 있다. Batch 1~3에는 <500 셀이 없어 중간/장수명만 표시했다. 선은 중앙값, 음영은 IQR이다.

해석·시사점: 그룹 곡선의 차이는 후보 신호를 보여준다. 그래프의 분리 정도나 상관계수만으로 예측 정확도를 주장하지 않고 DAY 2 검증으로 확인한다.

Q3-3. Batch 내 상대 수명 비교




Batch	수명 하위 25%: n / 범위	수명 상위 25%: n / 범위	log Δ Q 분산 중앙값: 하위 / 상위
Batch 1	9 / 534~651	9 / 876~1,074	-3.433 / -4.046
Batch 2	10 / 392~437	10 / 514~1,186	-3.339 / -4.231
Batch 3	10 / 541~825	10 / 1,146~1,935	-3.975 / -4.417

관찰: 각 Batch 내부의 수명 하위·상위 집단을 비교해도 하위 집단의 로그분산 중앙값이 더 높다. 선은 중앙값, 음영은 IQR이며 신뢰구간이 아니다. 경계 동률은 포함하므로 정확히 25%가 아닐 수 있다.

시사점: 절대 기준의 빈 집단을 가짜로 만들지 않고 Batch 내 상대 차이로 보완한다. 이 집단 구분은 전체 수명을 이용한 EDA 전용이며 예측 입력에는 넣지 않는다.


Q4- 1. Batch 1 충전 정책별 수명



관찰: 정책당 표본은 대체로 1~3개이다. 평균 순위 차이가 보여도 일부 장수명 정책은 종료 미확인 셀을 포함하므로 이 순위를 확정 수명 순위로 사용하지 않는다.

막대는 정답이 있는 전체 셀의 평균, 오차막대는 ± 1 표준편차이다(n=1은 추정 불가). (new)는 원문의 -newstructure를 뜻하며 다른 정책으로 유지했다. 단위: 사이클.


Q4-2. Batch 2 충전 정책별 수명



관찰: 4.8C(80%)-4.8C는 일반 조건 483.6(n=5), newstructure 871.7(n=3)이다. 동일한 C-rate 표기만으로 수명 차이를 설명할 수 없다.

막대는 정답이 있는 전체 셀의 평균, 오차막대는 ± 1 표준편차이다(n=1은 추정 불가). (new)는 원문의 -newstructure를 뜻하며 다른 정책으로 유지했다. 단위: 사이클.


Q4-3. Batch 3 충전 정책별 수명



관찰: 정책당 수명 편차가 있고, 두 단계 등가 C-rate는 약 4.794~4.813으로 좁다. 제한된 범위에서 속도-수명 관계가 약하다는 결과를 넓은 C-rate 범위에 일반화하지 않는다.

막대는 정답이 있는 전체 셀의 평균, 오차막대는 ± 1 표준편차이다(n=1은 추정 불가). (new)는 원문의 -newstructure를 뜻하며 다른 정책으로 유지했다. 단위: 사이클.

Q4-4. 충전 속도와 초기 열화




Batch	C _{eq} -수명 r	C _{eq} -초기 기울기 r	실측 전류-초기 기울기 r
Batch 1	-0.580	-0.617	-0.016
Batch 2	+0.334	-0.333	-0.404
Batch 3	-0.020	0.269	-0.374

$C_{eq} = 0.8 / (p/C1 + (0.8-p)/C2)$, p =전환 SOC/ 100. 0~80% SOC의 두 단계 등가 속도이며 CV·휴지 구간을 포함한 실제 충전시간과 다르다. 실측 전류는 cycle 10의 양의 I 값의 95백분위수이다.

해석·시사점: 빠를수록 항상 짧다는 전역 규칙은 지지되지 않는다. 정책·구조·배치가 함께 달라질 수 있으므로 정책 그룹 검증과 보조 피처 비교로 반영한다.

Q4-5. 충전 전류 패턴




관찰: cycle 10의 충전 전류를 Batch별 최단·중앙 순위·최장 셀에서 직접 확인했다. 충전 단계 전환과 후반의 전류 감소는 하나의 C-rate 수치가 생략하는 시간 정보를 보여준다. 그래프는 첫 양의 전류부터 첫 음의 방전 전류 직전 구간이다.

관측량	해석 가능한 정보	해석의 한계
정책 C1 / 전환 SOC / C2	설정된 두 단계 급속충전 조건	후반 정전압 충전·휴지 시간을 포함하지 않는다.
실측 양의 전류 P95	cycle 10 전류 크기의 상단을 요약	시간 가중 평균·에너지·전체 패턴을 대신하지 않는다.
전류 P95-초기 QD 기울기 r	Batch별 -0.016 / -0.404 / -0.374	설정 조건과 구조 차이가 섞여 인과 추정은 아니다.

시사점: P95는 패턴의 보조 진단 지표로 유지한다. 본 모델은 ΔQ 대표량부터 시작하고 충전 조건의 추가 가치는 정책 그룹 내부 검증으로 판단한다.


Q5- 1. 피처와 수명의 상관관계



관찰: ΔQ 로그분산은 일관되지만 충전시간은 $+0.571/-0.919/+0.599$ 로 부호가 바뀐다. 온도와 초기 QD 기울기도 배치별 강도·방향이 다르다. Pooled 열은 Batch 차이가 섞인 값이다.

시사점: 가장 강한 pooled 상관 하나로 피처를 선정하지 않는다. 예측에 쓰는 후보는 Batch 1 내부 검증으로 비교하고, Batch 2·3 관찰은 일반화 위험을 설명하는 데 사용한다.

Q5-2. 피쳐 다중공선성




Batch	log_dq_var vs dq_std	dq_mean vs dq_area	Tavg vs Tmax
Batch 1	0.991	1.000	0.949
Batch 2	0.980	1.000	0.831
Batch 3	0.974	1.000	0.969

관찰: Batch 1에서 Tavg-Tmax $r=0.949$, log_dq_var-dq_std $r=0.991$, ΔQ 평균-면적 $r \approx 1$ 이다. 특히 $\log_{10} \text{Var} = 2 \log_{10} \text{Std}$ 이므로 분산과 표준편차는 독립 정보가 아니다.

시사점: log_dq_var를 대표로 시작한다. 온도는 Tavg 하나, ΔQ 계열은 대표량 우선으로 구성하고 Ridge/ElasticNet의 규제를 사용한다. 상관이 약하다는 이유만으로 변수의 물리적 영향이 없다고 단정하지 않는다.

Q5-3. 핵심 피처 분포 비교



관찰: ΔQ 로그분산·충전시간·온도·저항 등은 Batch별 분포가 다르고, Batch 3의 등가 C-rate는 매우 좁은 범위에 모인다. 박스는 중앙값과 IQR, 점은 개별 셀이다. 수치 요약과 결측 수는 `feature_distributions.csv`에 저장했다.

시사점: 전체 데이터를 먼저 표준화하지 않는다. 학습 fold에서만 중앙값 대치·표준화를 적합하며, 외부 Batch의 범위 이탈과 오차를 함께 보고한다. 단일 배치에서 변동이 작다고 모든 환경에서 무의미한 변수라 결론내리지 않는다.

Q5-4. 상관 순위와 정제 민감도

Batch	절대 Pearson 최강 피처 / r	절대 Spearman 최강 피처 / ρ
Batch 1	log_dq_var / -0.827	log_dq_var / -0.826
Batch 2	chargetime_median / -0.919	chargetime_median / -0.810
Batch 3	log_dq_var / -0.742	log_dq_var / -0.759

Batch	log Δ Q 분산: 전체 유효 정답 r	품질 점검 후 r	해석
Batch 1	-0.886	-0.827	제외 규칙 적용 전후의 방향·강도 비교
Batch 2	-0.902	-0.902	제외 규칙 적용 전후의 방향·강도 비교
Batch 3	-0.702	-0.742	제외 규칙 적용 전후의 방향·강도 비교

해석: 배치마다 최고 순위의 피처가 같을 필요는 없다. 주피처는 한 배치의 최대 상관만으로 고르지 않고 여러 배치에서의 방향, 중복성, 초기 관측 가능성과 단순성을 함께 고려한다.

시사점: log_dq_var를 대표 피처로 시작한다. 여기서 상관을 확인한 것은 모델 성능 검증이 아니다. 제외 규칙에 따른 선택 편향과 배치 효과를 남은 한계로 명시하고, 새 미관찰 배치로 확인한다.

03. 피처 및 타깃 선정

선택: 초기 100사이클 기반 회귀. 타깃은 제공 cycle_life이며, log10 타깃 변환을 비교하고 평가 때 원래 사이클 단위로 복원한다. 분류는 Batch 1의 500 미만 표본이 없어서 선택하지 않았다.

집합 / 변수	EDA 근거	설계 결정
F1: log_dq_var	세 Batch에서 음의 상관 방향 유지	한 피처 회귀를 기준으로 시작
F2: F1 + qd_slope + c_equiv	초기 변화·충전 조건의 보완 가능성, 배치별 관계 차이	Batch 1 내부 CV에서 추가 가치가 있는지 비교
F3: F2 + tavg_median + ir_median	단독 관계는 약하지만 조합 효과 가능	제한된 민감도 실험
dq_std / dq_mean / dq_area / Tmax 동시 투입	대표 ΔQ/온도 피처와 높은 공선성	우선 제외
충전시간 / 정책 원핫 / newstructure	부호 변화, 희소 범주, 학습 배치에 없는 조건	우선 보류; 그룹·오류 분석으로 추적
cell_id, batch, n_cycles, last_qd, knee	식별자 또는 미래·정답 정보	입력 금지

정제 전후 상관은 correlations.csv에 scope=all_labeled / quality_screened로 함께 저장했다. 관측 종료와 채널 품질 조건을 바꾸면 결과가 달라질 수 있으므로 향후 민감도 결과도 보고한다.

04. 후보 모델 선정

후보	왜 이 모델인가?	DAY 2 비교 설정
중앙값 DummyRegressor	학습이 단순 수명 평균/중앙값보다 유용한지 확인	원래 cycle_life 중앙값 기준
Ridge 우선	36개 학습 후보, 중복 피처와 작은 표본에 규제 필요	alpha: 0.1, 1, 10, 100
ElasticNet	제한된 변수 선택과 계수 축소를 함께 비교	alpha: 0.001, 0.01, 0.1 / l1_ratio: 0.2, 0.8
얕은 RandomForest	비선형 비교군. 과적합과 수명 범위 외삽 한계 점검	n_estimators=300, max_depth=2~3, min_samples_leaf=3~5

공통 전처리: 결측 중앙값 대체 → 필요한 모델에 표준화 → 모델 적합을 Pipeline으로 구성한다. 대체·표준화는 각 교차검증 fold의 학습 부분에만 fit한다. 학습 피처는 초기 사이클 화이트리스트로 고정한다.

피처 설계 논리: F1은 세 Batch에서 방향이 일관된 log_dq_var 하나로 시작한다. F2는 초기 용량 변화(qd_slope)와 충전 조건(c_equiv)을 더해 ΔQ 만으로 놓칠 수 있는 정보를 확인한다. F3는 온도·저항을 제한적으로 추가한다. ΔQ 표준편차·평균·면적과 Tmax는 대표 피처와 중복이 커 동시에 넣지 않는다.

모델 선택 논리: DummyRegressor는 피처가 실제로 기준선보다 나은지 확인하는 출발점이다. 작은 표본과 공선성에는 Ridge/ElasticNet이 계수 폭주를 줄여 적합하다. RandomForest는 비선형 비교군일 뿐, 학습 수명 범위 밖 예측이 약하므로 최종 선택의 기본값으로 두지 않는다.

선택 기준: Train 내부 그룹 CV의 MAPE 평균과 변동성을 우선 확인하고, 비슷한 성능이면 적은 피처·단순 모델을 선택한다. 소표본이므로 큰 하이퍼파라미터 탐색이나 딥러닝을 우선하지 않는다.

외삽 위험: 주분석 Batch 1 수명은 534~1,074이지만 Batch 2는 392, Batch 3은 1,935까지 포함한다. 특히 트리는 학습 타깃 범위 밖으로 일반화하기 어렵다. 낮은 평균 오차만으로 장수명 추정 신뢰성을 주장하지 않는다.

05. 검증 및 평가 설계

단계	설계	의미
1. 내부 분리	Batch 1 36셀 → 정책 그룹 단위 train 29 / validation 7. 정책 16 / 4, 난수 42	동일 정책과 동일 셀의 분리 간 중복 없음
2. 모델 선택	train 29셀에서 4-fold GroupKFold. 전처리는 fold 내부 fit	F1~F3와 좁은 후보군 비교
3. 내부 확인	선택 후 validation 7셀에서 한 번 확인	소표본 변동성과 과적합 확인
4. 외부 Batch 평가	절차 동결 → Batch 1 36셀 재학습 → Batch 2 39셀 / Batch 3 40셀 평가	테스트 성능을 보고 튜닝 반복하지 않음

주지표: $MAPE(\%) = \text{mean}(|\text{실제}-\text{예측}|/\text{실제}) \times 100$.

보조지표: MAE·RMSE(사이클), R^2 .

결과 보고: Train·validation·Batch 2·Batch 3 성능표, 실제-예측 산점도, 잔차, 수명 구간·정책별 큰 오차.

논문 9.1%는 다른 데이터 정제·분할 조건의 참고 수치이다. 이번 실험의 측정 성능이나 재현 보장으로 사용하지 않는다. (1)

06. 재현 방법 및 활용 범위

산출물	역할
notebooks/01_data_check.ipynb	파일 구조·품질·제외 이유·원본 SHA-256·라이브러리 버전
notebooks/02_day1_eda.ipynb	다섯 질문의 그래프·표·해석·모델 설계, 실행 출력 포함
src/day1_analysis.py	선택적 HDF5 로더, 피처 계산, 그림·표 생성 함수
results/day1/figures · tables	고해상도 PNG 17개, 셀 피처·품질·정책·상관·분리 계획 CSV

DAY 1 결과 보고서 results/DS-MINI-Design-SKALA_3반-U095_이연주.pdf

실행: 프로젝트 .venv 커널을 선택해 01 → 02 순서로 Restart & Run All 한다. requirements.txt에서 실행 패키지를 확인한다.

ESS 활용: 셀 수명 선별·교체 우선순위 연구에 활용할 수 있다. 실제 ESS는 온도, 부하, 달력 열화, 팩 불균형이 달라 외부 운전 데이터 검증이 필요하다. 입력 분포 변화와 정답 확보 후 오차 증가를 모니터링하고 새 배치 검증 후 재학습한다.

참고자료

[1] Severson, K. A., Attia, P. M., Jin, N., et al. (2019). Data-driven prediction of battery cycle life before capacity degradation. Nature Energy, 4, 383-391. DOI: 10.1038/s41560-019-0356-8.

[2] 저자 공개 데이터 처리 코드: github.com/rdbraatz/data-driven-prediction-of-battery-cycle-life-before-capacity-degradation (Load Data.ipynb, LoadData.m, README). 2026-10-01 확인. 모델 코드를 복사하지 않고 분석 함수를 직접 구현했다.